

Dokumentacja Wewnętrzna Projektu

Ten dokument opisuje szczegóły implementacyjne, strukturę plików oraz mechanizmy działania systemu **Lokalna-Instalacja-LLM**.

1. Struktura Projektu

Główne katalogi projektu i ich przeznaczenie:

- `/pipelines`: Zawiera definicje pipeline'ów Open WebUI (np. Smart Mode, Safe Mode).
 - `/utils`: Moduły pomocnicze (logika moderacji, wyboru modelu, śledzenia aktywności).
- `/scripts`: Skrypty administracyjne i automatyzacyjne (auto-setup, migracje).
- `/customization`: Pliki do budowy zmodyfikowanej wersji Open WebUI (Dockerfile, CSS).
- `/docs`: Dokumentacja projektu (w tym ten plik).
- `/data`: Katalogi na dane wolumenów (Docker).

2. Opis Komponentów (Pipelines/Utils)

2.1 ModelSelector (`model_selector.py`)

Odpowiada za dynamiczny dobór modelu LLM na podstawie dostępnej pamięci RAM.

- **Funkcja:** `get_model_by_ram(ram_gb)`
- **Tryby:**
 - `Light`: gemma2:2b (RAM < 8GB)
 - `Balanced`: llama3:latest (RAM 8-16GB)
 - `Advanced`: llama3.1:latest (RAM > 16GB)

2.2 Moderator (`moderator.py`)

Zapewnia bezpieczeństwo interakcji poprzez filtrowanie treści.

- **Funkcje:**
 - `detect_pii(text)`: Wykrywa dane osobowe (PESEL, e-mail, telefon).
 - `check_banned_words(text)`: Blokuje wulgarne lub niedozwolone słownictwo.
 - `detect_jailbreak(text)`: Próba wykrycia złośliwych promptów hackingowych.

2.3 ActivityTracker (`activity_tracker.py`)

Monitoruje wydajność i statystyki użycia.

- **Dane:** Zapisuje czas odpowiedzi, liczbę tokenów, użyty model i datę.
- **Persystencja:** Plik `pipelines/activity_data.json`.

3. Infrastruktura (Docker)

System składa się z 5 usług:

1. **ollama**: Główny backend modeli.
2. **ollama-init**: Pobiera wymagane modele przy pierwszym uruchomieniu.
3. **pipelines**: Silnik niestandardowych operacji pośredniczących.
4. **open-webui**: Interfejs użytkownika z nałożonymi stylami CSS.

2. **ollama-init**: Pobiera wymagane modele przy pierwszym uruchomieniu.
3. **pipelines**: Silnik niestandardowych operacji pośredniczących.
4. **open-webui**: Interfejs użytkownika z nałożonymi stylami CSS.
5. **auto-setup**: Automatycznie tworzy użytkowników i konfiguruje system po starcie.

4. Konfiguracja Portów i Linków

- Open WebUI: <http://localhost:3000>
- Pipelines API: <http://localhost:9099>
- Ollama API: <http://localhost:11434>

Standardowy klucz API dla pipeline'ów: `0p3n-w3bu1`.

5. Procedura Rozwoju

Aby dodać nową funkcjonalność:

1. Dodaj skrypt w `/pipelines`.
2. Jeśli potrzebuje nowych bibliotek, dopisz je do `pipelines/requirements.txt`.
3. Zrestartuj kontener `pipelines`: `docker-compose restart pipelines`.